



Registro de Fontes e Preparação dos Dados — Projeto Prazo60

Amanda Barral - RM 569662
Eduardo Bambulim - RM 573228
Gabriela Fernandes - RM 568972
Julia Furiate - RM 570547
Lívia Santos - RM 573963

São Paulo, SP - 2026

1. Introdução

Este documento tem como objetivo apresentar a origem, as fontes e as evidências relacionadas aos dados utilizados no desenvolvimento do projeto Prazo60. A documentação busca demonstrar de forma clara de onde as informações foram obtidas, quais critérios foram utilizados para a composição da base e como os dados foram preparados para serem utilizados nas etapas seguintes do projeto.

A principal fonte de dados utilizada foi o Pannel de Oncologia do DATASUS, a partir do extrato referente aos casos de câncer de mama feminino no Estado de São Paulo. Além da fonte primária, foram utilizadas informações complementares para identificação territorial e das unidades de saúde, permitindo organizar os registros e relacioná-los às análises propostas pelo projeto.

Ao longo deste documento, são apresentadas evidências da obtenção dos dados, as principais variáveis presentes no extrato original e as etapas realizadas para sua preparação. Dessa forma, o material contribui para a transparência e rastreabilidade da base utilizada, permitindo compreender a origem dos dados que posteriormente alimentam o banco de dados, os indicadores e o painel desenvolvido para o Prazo60.

2. Dados e Arquitetura

O Prazo60 integra três componentes:


Pipeline de dados em Python/Pandas, que trata o extrato bruto do DATASUS e aplica as regras de negócio do projeto (cumprimento do prazo, deslocamento intermunicipal, decodificação de tratamento/estadiamento, faixa etária);

Modelo relacional no Oracle Database, que organiza os dados em entidades (região de saúde, município, unidade de saúde, caso, tratamento) e expõe uma view (VW_FILA_PRAZO) que calcula dinamicamente os dias de espera de cada caso frente à lei;

Painel em Power BI, que consolida os indicadores em três frentes — visão executiva, pressão regional e perfil epidemiológico — permitindo também consultas em linguagem natural via Select AI.

ARQUITETURA MODERNA DE DADOS – PRAZO 60

Arquitetura Lambda para processamento de dados históricos e em tempo real








2.1 Dados e fontes utilizadas

Fonte primária: Painel de Oncologia do DATASUS (POBR/TabNet), extrato POBR_2022_2026_SP_mama_feminino.csv, filtrado para CID-10 C50 (câncer de mama), sexo feminino, Estado de São Paulo, no período de 2022 a maio de 2026 — totalizando 46.181 casos. Fonte complementar de referência territorial: divisão dos Departamentos Regionais de Saúde (DRS/SP), utilizada para agrupar municípios por região de saúde. Fonte de identificação de unidades: código CNES das unidades de diagnóstico e tratamento presentes no extrato.

Principais variáveis do extrato bruto: TEMPO_TRAT (dias entre diagnóstico e início do tratamento), MUN_RESID/MUN_TRATAM (município de residência e de tratamento), TRATAMENTO (modalidade), ESTADIAM (estágio do tumor), IDADE, DT_DIAG/DT_TRAT.

Acesso a dados brutos do DATASUS através do caminho Windows -> Explorador de arquivos -> e cola o endereço <ftp://ftp.datasus.gov.br/>





2.2 Tratamento e preparação dos dados

O tratamento dos dados foi feito em Python, com a biblioteca Pandas, por meio do script `pipeline_datasus.py`.

A escolha por tratar os dados em Python (e não via Power Query, dentro do próprio Power BI) foi justificada pela equipe por três razões: desempenho e escalabilidade (Pandas processa volumes grandes com menor consumo de memória), reuso e governança (o mesmo script tratado pode alimentar Power BI, banco relacional e futuros modelos, sem duplicar a regra de negócio em lugares diferentes) e portabilidade (uso de caminhos dinâmicos via `os.path`, evitando erro de arquivo não encontrado em outras máquinas).

